

繁體中文 Tokenizer 碎片化對 LLM 語境腐化的影響

Needle-in-a-Haystack 實驗與架構世代分析

研究者：Dave Chen

日期：2026-04-13

研究動機

繁體中文因字形複雜度高，在主流 LLM tokenizer 中產生**更多 token**

實測 Token Overhead（prompt 級，非字元級估算）：

Tokenizer 家族	代表模型	繁體 Overhead
Gemma 3/4	gemma3:4b 等	+5.9%
LLaMA 3	llama3.1:8b	+7.2%
Qwen 3.5	qwen3.5:2b–35b	+10.3%

65K 字元文件：繁體比簡體多消耗 2,714–3,849 tokens

核心問題：這些額外 token 是否使語境腐化（context rot）更早發生、更快惡化？

實驗設計

方法：Needle-in-a-Haystack (NIAH) 檢索任務

三種 Variant (控制變因：僅改變文字腳本)

Variant	Haystack	Question	簡稱
繁問繁答	繁體	繁體	trad
繁問簡答	簡體	繁體	simp
簡問簡答	簡體	簡體	simp_q

實驗矩陣：12 長度 × 11 位置 × 5 needle × 10 重複 = **1,320 trials / variant / model**

模型：16 個 (Dense 1B–70B + MoE 2B/4B active)，Q4_K_M 量化

RQ1：Token 膨脹是否使腐化時機點提前？

65K 字元下三 Variant 對比（reeval，評估標準一致）

模型	繁問繁答	繁問簡答	簡問簡答	差距
gemma3:4b	88.2%	93.6%	92.7%	+4.5pp
llama3.1:8b	92.7%	94.5%	96.4%	+3.6pp

- 三 variant 排序符合假說：簡問簡答 $\approx$ 繁問簡答 > 繁問繁答
- 問題語言影響小（0.9–1.9pp），**context 語言**是主要因素
- gemma3:4b 繁體在 12K 字元即開始滑落，簡體在 16K 仍穩定

RQ2：Token 膨脹是否影響腐化速率？

gemma3:4b — 退化最清晰的 benchmark

字元數	繁問繁答	簡問簡答	差距	觀察
12K	99.1%	100.0%	-0.9pp	繁體略早滑落
65K	88.2%	92.7%	-4.5pp	差距最大
100K	68.2%	68.2%	0pp	差距歸零
130K	52.7%	52.7%	0pp	差距歸零

結果：(a) 僅時機點提前（曲線左移），速率未加快
到 100K+，繁/簡 token 差（~2,700）相對總量（~75K+）已不顯著

RQ2 (續)：llama3.1:8b 的反轉現象

字元數	繁問繁答	簡問簡答	差距
65K	92.7%	96.4%	-3.6pp (符合假說)
100K	90.9%	91.8%	-0.9pp
130K	91.8%	82.7%	+9.1pp (反轉)

- 130K 繁體反勝簡體 9.1pp，方向違反假說
- 可能原因：訓練分布偏差、統計噪音（僅 110 筆 @130K）
- 無法歸類為 (a)(b)(c) 任一種退化模式

位置敏感度：質性佐證

gemma3:4b — 繁/簡的注意力分布差異

位置	繁問繁答	繁問簡答（簡體 context）
0.0（開頭）	100%	100%
0.3	86.7%	99.0%
0.5（中段）	80.8%	98.0%
0.7	92.5%	100%
1.0（結尾）	100%	100%

繁體：明顯 **Lost in the Middle**（中段 0.81）

簡體：幾乎平坦（0.98–1.0）

相同問題語言，不同 context 腳本 → **tokenizer overhead** 加劇中段注意力稀釋

探索性發現：架構世代壓倒 Tokenizer 效應

模型	架構	overhead	繁問繁答 @130K	簡問簡答 @130K
gemma3:4b	Dense 4B, Gemma 3	+5.9%	52.7%	52.7%
gemma4:e2b	MoE 2B active, Gemma 4	+5.9%	100.0%	100.0%
qwen3.5:2b	Dense 2B , Qwen 3.5	+10.3%	99.1%	100.0%
llama3.1:8b	Dense 8B, LLaMA 3	+7.2%	91.8%	82.7%

- **Qwen3.5**：overhead 最高（+10.3%）卻完全免疫
- **Gemma4 e2b**：僅 2B 活躍參數，@130K = 100%
- 架構升級效果（+47pp）遠大於繁/簡差異（1.8–5.4pp）

為什麼新架構免疫？三個關鍵改進

1. 注意力機制：從 $O(n^2)$ 到混合架構

世代	機制	長 context 表現
LLaMA 3.x	純 softmax ($O(n^2)$)	128K 後品質衰減
Gemma 4	Sliding window + global (5:1 交錯)	256K stable
Qwen 3.5	Gated DeltaNet + full softmax (3:1 交錯)	262K 原生，1M 可擴展

2. 位置編碼：自適應縮放

- **Gemma 4**：Proportional RoPE (p-RoPE) — 隨序列長度等比縮放
- **Qwen 3.5**：YaRN + NTK-aware — 高頻少縮、低頻多縮

3. KV Cache 共享 (Gemma 4)

- 後 N 層複用前面層 K/V → 降低記憶體壓力 + 量化穩定性

新架構為何特別幫助繁體中文？

安全餘量吸收 overhead

繁體 130K 字元 $\approx$ 98K tokens

Gemma 3 (有效 ctx $\sim$ 77K tokens) $\rightarrow$ 127% 利用率 $\rightarrow$ 已超限
Qwen 3.5 (有效 ctx 262K tokens) $\rightarrow$ 37% 利用率 $\rightarrow$ 極安全

混合注意力消除 Lost in the Middle

Sliding window 層只看局部窗口，不受全局長度影響

$\rightarrow$ 繁體多 5.9% tokens 不再稀釋中段注意力

線性注意力對 token 密度不敏感

GDN 壓縮為固定大小 state

$\rightarrow$ 90K tokens (簡體) 和 98K tokens (繁體) 壓縮後相同

模型行為四類模式

模式	代表模型	特徵	適合研究？
A 硬性上限	gemma3:1b, qwen3:8b	突然崩潰（ctx 截斷）	否
B 漸進退化	gemma3:4b, llama3.1:8b	準確率單調下降	最佳
C 突發崩潰	gemma3:27b	pad token 輸出退化	否
D 近乎完美	Gemma4, Qwen3.5 全系列	天花板效應	否（需 200K+）

繁體 context rot 的可觀測窗口僅存在於模式 B 的特定 context 長度區間

宣稱 Context Window vs 實際有效範圍

模型	宣稱 ctx	腐化起始點	有效利用率
gemma3:1b	128K	4,661 tokens	3.6%
gemma3:4b	128K	49,323 tokens	38.5%
llama3.1:8b	131K	57,583 tokens	43.9%
gemma3:12b	128K	75,847 tokens	59.3%
Qwen3.5 全系列	262K	無 (>130K 測試範圍)	—
Gemma4 全系列	256K	無 (>130K 測試範圍)	—

宣稱 128K ≠ 可靠使用 128K

繁體輸入的額外 overhead 進一步壓縮實際可用範圍

理論限制（討論章節）

Token 碎片化的雙效應（不可分離）

1. **Token 數量增加** → 佔用更多 context window
2. **語意密度降低** → 每 token 資訊量下降

兩者在現有設計下無法分離 → 作為機制詮釋，非獨立可測變數

英語樞紐機制（Latent Pivot）

- 模型中間層可能以英語語意空間推論
- 關閉 thinking mode 不影響此機制
- 可能部分抵消 token 膨脹效應
- 作為無法排除的干擾因素陳述

結論

已建立

1. 架構世代是壓倒性主因，tokenizer overhead 最多是次要加重因子
2. 脆弱模型中繁體確實加速退化 (65K: +1.8–5.4pp)，三 variant 排序符合假說
3. 效應模式為曲線左移 (onset 提前)，非速率加快
4. 效應在極長 context 下非單調 (歸零或反轉)

未建立

- overhead-performance 定量關係 (Qwen3.5 反例)
- llama3.1:8b @130K 反轉機制
- 前沿模型的真實臨界點 (天花板效應)

實務建議

繁體中文長文件處理 → 優先選擇 Qwen 3.5 或 Gemma 4 系列

下一步

近期（進行中）：

1. 補完 llama3.3:70b 簡問簡答（目前 502/1320 筆）
2. 調查 llama3.1:8b @130K 反轉現象

中期：

3. 擴充至 200K+ 字元，克服天花板效應
4. 英文 baseline（模型能力理論上限參考）

參考文獻

主題	來源
Gemma 3 架構	Gemma Team. <i>Gemma 3 Technical Report</i> . arXiv:2503.19786
Gemma 4 架構	Google DeepMind. <i>Gemma 4 Model Card</i> . ai.google.dev
Qwen 3/3.5 架構	Qwen Team. <i>Qwen3 Technical Report</i> . arXiv:2505.09388
LLaMA 3 架構	Grattafiori et al. <i>The Llama 3 Herd of Models</i> . arXiv:2407.21783
YaRN 位置編碼	Peng et al. <i>YaRN: Efficient Context Window Extension</i> . arXiv:2309.00071
架構效率比較	arXiv:2604.07035

實驗數據與程式碼：<https://github.com/dave0629g/context-rot-zh>